

PROGETTO BANDI

Sistema di scraping multi-fonte e matching intelligente
tra bandi pubblici italiani ed entità potenzialmente interessate

Report di stato — 07 May 2026

IDEA-RE | atenerini@idea-re.eu

DB snapshot: 1064 bandi · 533 entità · 14,960 match calcolati

1. Executive summary

Cos'è. BANDI è un sistema software che raccoglie automaticamente bandi pubblici italiani ed europei da quattro fonti ufficiali, costruisce in parallelo un catalogo di potenziali partecipanti (aziende, ricercatori, università, enti) e calcola un punteggio di affinità tra ogni bando e ogni entità del catalogo.

Perché serve. Il volume di opportunità pubbliche è alto e la maggior parte non è specifica per il destinatario ideale: serve un filtro automatico che proponga, per ciascun bando, le entità più rilevanti (e viceversa). Lo strumento non sostituisce la valutazione umana: produce una shortlist ordinata su cui concentrare l'analisi qualitativa.

Risultati attuali.

- **1064** bandi importati da TED, OpenCoesione, MUR (ANAC bloccato lato fonte)
- **533** entità profilate con **3,703** segnali (concetti OpenAlex, temi OpenCoesione, topic GitHub, metriche, ecc.)
- **14,960** coppie bando→entità valutate, top-20 salvate per ogni bando attivo
- Copertura geografica: 261/1064 bandi e 113/533 entità hanno regione persistita
- Matcher a **6 componenti pesati** (tipo, settori, concept, keyword, peso, geo) — risultati validati su 4 scenari diversi nel capitolo 6

2. Architettura

Il sistema è uno script Python con database SQLite locale. Tre livelli logici, ognuno con il proprio package:

```
BANDI/  
■■■ scraper/      # acquisizione bandi (TED, OpenCoesione, MUR, ANAC)  
■■■ entity/       # acquisizione entità (OpenAlex, CORDIS, OC, GitHub)  
■■■ matching/    # motore di scoring composito  
■■■ data/db/     # SQLite con schema unificato  
■■■ scripts/     # utility one-shot (backfill, re-enrich, report)  
■■■ main.py      # CLI: --bandi --entita --match --show ID
```

2.1 Fonti dei bandi

Fonte	Endpoint	Metodo	Bandi salvati
TED	api.ted.europa.eu/v3	API REST + filtro form-type	622
OpenCoesione	opencoesione.gov.it/it/api	API REST per tema	440
MUR	www.mur.gov.it (HTML)	Scraping HTML + 2 PRIN hardcoded	2
ANAC	dati.anticorruzione.it	CSV bulk OCDS (bloccato da WAF)	0

■ ANAC: il portale blocca i download automatici via WAF (Web Application Firewall). Il codice *scraper/anac_scraper.py* riconosce il blocco e stampa istruzioni per il download manuale.

2.2 Fonti delle entità

Fonte	Tipo entità coperto	Segnali estratti
OpenAlex	Università, ricercatori	concept tematici, h-index, works/citations, ROR
CORDIS / OpenAIRE	Organizzazioni IT con progetti UE	PIC code, OpenAIRE id, keyword progetti

Fonte	Tipo entità coperto	Segnali estratti
OpenCoesione (soggetti)	Aziende, regioni, ministeri	multi-tema, sede, P.IVA, n. progetti, costo pubblico totale
GitHub	Software house, organizzazioni tech	topic, linguaggi, descrizione, n. repo, follower
ANAC winners	Aggiudicatari (richiede CSV ANAC)	CPV vinti, importi storici, contratti

2.3 Pipeline di esecuzione

```
python main.py --bandi      # scarica bandi da tutte le fonti
python main.py --entita     # scarica/arricchisce le entita
python main.py --match      # ricalcola tutti i match (top-20)
python main.py --stats      # statistiche del DB
python main.py --show ID    # top match per un bando
python main.py --for-entity NOME # bandi rilevanti per un'entita
```

3. Schema del database

SQLite singolo file: *data/db/bandi.db*. Schema relazionale con tre cluster logici: bandi (+ tabelle satellite), entità (+ segnali e contratti), match.

3.1 Tabelle bandi

Tabella	Colonne principali	Descrizione
bandi	id (PK), fonte, tipo, titolo, descrizione, ente_nome, regione, importo_stimato, data_scadenza, stato, url	Tabella centrale dei bandi
bandi_settori	bando_id, settore (entrambi PK)	Settori inferiti (1:N)
bandi_destinatari	bando_id, destinatario	Tipi di destinatario validi (aziende, universita, ...)
bandi_cpv	bando_id, cpv_code	Codici CPV europei (1:N)

3.2 Tabelle entità

Tabella	Colonne principali	Descrizione
entita	id (PK), tipo, nome, piva, ateco, dimensione, sede_citta, sede_regione, paese, sito_web, email	Anagrafica delle entità
segnali	id, entita_id, tipo, valore, peso, fonte, raw	Indicatori di interesse (1:N) — modello a chiave/valore tipizzato
contratti_vinti	id, entita_id, cpv, importo, ente_appaltante, anno, fonte	Storico aggiudicazioni ANAC
pubblicazioni	id, entita_id, titolo, anno, concetti_json, doi, openalex_id	Pubblicazioni OpenAlex

3.3 Tabella match

Tabella	Colonne principali	Descrizione
match_scores	bando_id, entita_id (PK composta), score, dettaglio_json, calcolato_at	Top-20 entità per ogni bando attivo. Il dettaglio JSON contiene il breakdown dei 6 componenti.

Esempio di record dettaglio_json

```
{
  "score": 0.690,
  "tipo": 1.000,
  "settori": 0.300,
  "concept": 1.000,
  "keyword": 0.000,
  "peso": 0.870,
  "geo": 0.500
}
```

4. Stato dei dati (snapshot live)

Snapshot del DB al 07 May 2026.

4.1 Conteggi tabelle

Tabella	Record
Bandi	1,064
Entità	533
Segnali	3,703
Match scores	14,960
Contratti vinti	0
Pubblicazioni	0

Contratti e Pubblicazioni a 0: dipendono da CSV ANAC (WAF) e dall'ingestion delle works OpenAlex (non lanciata in questa sessione, è opzionale).

4.2 Bandi per fonte e stato

Fonte	Stato	N
MUR	attivo	2
OpenCoesione	attivo	335
OpenCoesione	scaduto	105
TED	aggiudicato	44
TED	attivo	411
TED	scaduto	167

"aggiudicato": 44 bandi TED che erano in realtà esiti di gara già concluse, marcati come tali (non entrano nel matching).

4.3 Entità per tipo

Tipo	N
azienda	422
ricercatore	55
universita	46
ente_ricerca	10

4.4 Segnali per tipo (top 12)

Tipo segnale	N	Origine
oc_tema	1161	OpenCoesione (multi-tema da dettaglio soggetto)

Tipo segnale	N	Origine
openalex_concept	770	OpenAlex (autori e istituzioni)
oc_fondi_strutturali	489	OpenCoesione (presenza nel sistema)
oc_costo_pubblico_tot	377	OpenCoesione (importo totale)
oc_n_progetti	377	OpenCoesione (peso storico)
oa_citations	100	OpenAlex (impatto)
oa_works_count	100	OpenAlex (produttività)
istituzione	56	OpenAlex (affiliazione)
oa_h_index	50	OpenAlex (h-index)
openaire_id	50	OpenAIRE
openalex_ror	50	OpenAlex (Research Org Registry)
eu_pic_code	48	CORDIS (Participant Identification Code)

4.5 Top entità per numero di match

Entità	Tipo	N match	Best score
ISTITUTO NAZIONALE DELLA PREVIDENZA SOCIALE - INPS	azienda	493	0.700
Regione Sicilia	azienda	489	0.700
Regione Campania	azienda	468	0.727
REGIONE CALABRIA	azienda	464	0.723
REGIONE LAZIO	azienda	462	0.739
REGIONE SICILIANA	azienda	459	0.718
REGIONE PUGLIA	azienda	458	0.743
MIMIT - MINISTERO DELLE IMPRESE E DEL MADE IN ITAL	azienda	456	0.710

5. Logica del matching

Per ogni coppia (*bando*, *entità*) il motore calcola uno score composito normalizzato in [0, 1] come somma pesata di sei componenti indipendenti. Le top-20 entità per ciascun bando attivo vengono salvate in *match_scores*.

5.1 I sei componenti

Componente	Peso	Cosa misura	Output
tipo	0.30	Il tipo dell'entità è tra i destinatari ammessi dal bando?	1.0 match diretto, 0.4 partial, 0.0 nessuno
settori	0.20	Almeno un tema OC dell'entità matcha i settori del bando?	0.7 + 0.1 per ogni match (cap 1.0). 0.3 se nessun tema, 0.0 se tutti incompatibili
concept	0.15	I concept OpenAlex dell'entità corrispondono ai settori del bando (tramite mapping IT→EN)?	0.0 a 1.0 (frazione di concept che matchano)
keyword	0.10	Sovrapposizione Jaccard tra parole del titolo/descrizione bando e parole derivate da nome+segnali entità	Jaccard $ A \cap B / A \cup B $
peso	0.15	Dimensione/peso dell'entità (max log-scaled tra h-index, citations, n. progetti OC, n. repo GitHub)	0.0 a 1.0, 0.3 se nessuna metrica
geo	0.10	Match territoriale: regione bando vs sede entità	1.0 stesso, 0.5 ignoto, 0.0 diverso

5.2 Formula complessiva

```
score = 0.30 * tipo
        + 0.20 * settori
        + 0.15 * concept
        + 0.10 * keyword
        + 0.15 * peso
        + 0.10 * geo
```

Pesi tarati empiricamente: la copertura dati varia molto tra fonti, quindi il matcher deve restare informativo anche quando un componente non ha dato (es. concept=0 per le aziende, che non hanno profilo OpenAlex).

5.3 Esempio numerico

Caso: bando PRIN 2026 (ricerca nazionale, no regione) vs il ricercatore Gregg L. Semenza (Premio Nobel medicina 2019).

Componente	Valore	Peso	Contributo
tipo (ricercatore ∈ {ricercatori, enti_ricerca, universita})	1.00	0.30	0.300
settori (no oc_temi sull'entità)	0.30	0.20	0.060
concept (concept OpenAlex matchano 'ricerca')	1.00	0.15	0.150
keyword (overlap ridotto)	0.00	0.10	0.000
peso (h-index alto, citations alte)	0.87	0.15	0.130
geo (bando senza regione, neutro)	0.50	0.10	0.050

Componente	Valore	Peso	Contributo
TOTALE			0.690

6. Esempi di matching su scenari diversi

Quattro casi reali tratti dal DB attuale, scelti per mostrare comportamenti diversi del matcher.

6.1 PRIN 2026 — bando di ricerca nazionale

Campo	Valore
ID	MUR-PRIN-2026
Fonte	MUR
Titolo	PRIN 2026 — Progetti di Rilevante Interesse Nazionale
Regione persistita	(non popolata, geo neutro 0.5)
Stato	attivo
Importo stimato	€ 259.889.354

Top 5 entità correlate

#	Score	Tipo	Sede	Nome
1	0.690	ricercatore	—	Gregg L. Semenza
2	0.682	ente_ricerca	Lombardy	Istituto Nazionale di Fisica Nucleare, Sez
3	0.665	universita	—	University of Salerno
4	0.665	universita	Friuli Venezia Giulia	University of Trieste
5	0.665	universita	Umbria	University of Perugia

Breakdown del top match: tipo=1.00 · settori=0.30 · concept=1.00 · keyword=0.00 · peso=0.87 · geo=0.50

6.2 PIANO FSC RICERCA E INNOVAZIONE

Campo	Valore
ID	OC-2017FSCRICERCA
Fonte	OpenCoesione
Titolo	PIANO FSC RICERCA E INNOVAZIONE
Regione persistita	(non popolata, geo neutro 0.5)
Stato	attivo
Importo stimato	—

Top 5 entità correlate

#	Score	Tipo	Sede	Nome
1	0.688	ricercatore	—	Shi Xue Dou

#	Score	Tipo	Sede	Nome
2	0.674	azienda	Puglia	MINISTERO DELL UNIVERSITA E DELLA RICERCA
3	0.660	azienda	Lazio	MINISTERO DELL'ISTRUZIONE E DEL MERITO
4	0.660	azienda	Campania	Regione Campania
5	0.660	azienda	Lazio	REGIONE LAZIO

Breakdown del top match: tipo=1.00 · settori=0.30 · concept=1.00 · keyword=0.00 · peso=0.86 · geo=0.50

6.3 ACCORDO COESIONE LAZIO — territoriale

Campo	Valore
ID	OC-PSCLAZIO2021
Fonte	OpenCoesione
Titolo	ACCORDO COESIONE LAZIO - FSC ANTICIPAZIONI
Regione persistita	Lazio
Stato	attivo
Importo stimato	—

Top 5 entità correlate

#	Score	Tipo	Sede	Nome
1	0.430	ente_ricerca	Lazio	National Agency for New Technologies, Ener
2	0.430	universita	Lazio	University of Rome Tor Vergata
3	0.430	universita	Lazio	Roma Tre University
4	0.430	ente_ricerca	Lazio	National Research Council
5	0.430	universita	Lazio	Sapienza University of Rome

Breakdown del top match: tipo=0.40 · settori=0.30 · concept=0.00 · keyword=0.00 · peso=1.00 · geo=1.00

6.4 TED — Servizi di R&D; sperimentale

Campo	Valore
ID	TED-278990-2026
Fonte	TED
Titolo	Italia – Servizi di ricerca e sviluppo sperimentale – Avviso di modifica della Scheda Tecnica relativa ai Servizi di Inn
Regione persistita	(non popolata, geo neutro 0.5)
Stato	attivo

Campo	Valore
Importo stimato	—

Top 5 entità correlate

#	Score	Tipo	Sede	Nome
1	0.651	ricercatore	—	G. Della Ricca
2	0.650	ricercatore	—	G. Rolandi
3	0.650	ricercatore	—	P. Azzi
4	0.650	universita	—	University of Salerno
5	0.650	ente_ricerca	Lombardy	Istituto Nazionale di Fisica Nucleare, Sez

Breakdown del top match: tipo=1.00 · settori=0.30 · concept=0.75 · keyword=0.00 · peso=0.85 · geo=0.50

6.5 Letture chiave dagli esempi

- **PRIN nazionale:** top dominato da ricercatori e università con concept e peso alti. Il matcher si comporta come ci si aspetta da un bando di ricerca pura.
- **FSC nazionale macro:** i top sono ministeri/regioni (beneficiari diretti dei piani FSC, multi-tema con peso elevato). Limite noto: classificati come *azienda* per default fallback nello scraper OC.
- **FSC Lazio territoriale:** il geo_score=1.0 spinge in cima entità con sede in Lazio (ENEA, Sapienza, CNR, Roma Tre, Tor Vergata). Caso da manuale per dimostrare l'utilità del componente territoriale.
- **TED R&D:** mix di ricercatori e università, con concept_score elevato e peso forte sulle istituzioni produttive.

7. Evoluzione del matcher

Il sistema è passato da 4 a 6 componenti con interventi incrementali validati a ogni passaggio.

7.1 Stato di partenza

- 4 componenti: tipo (0.35), settori (0.30), concept (0.20), keyword (0.15)
- Aziende sempre con concept=0 (OpenAlex non copre il settore commerciale)
- Multi-tema penalizzato: una entità con 11 temi e 1 match aveva settori_score = 1/11 invece di 1.0
- 44 bandi TED erano esiti di gare già aggiudicate miscelati con i bandi attivi
- Metriche disponibili (works_count, citations, n_progetti, h-index) NON salvate nel DB

7.2 Fix applicati e effetto misurato

#	Fix	File	Effetto
1	Estensione enrichment OC: dettaglio soggetto → multi-tema, P.IVA, sede, totali progetti	entity/opencoesione_beneficiari.py	+607 segnali; popolata sede e P.IVA per 96 aziende OC
2	Logica OR su _settori_score: almeno 1 tema match → $0.7 + 0.1 * (\text{match} - 1)$	matching/match_engine.py	Multi-tema non più penalizzato
3	Filtro form-type su TED + flag stato 'aggiudicato'	scraper/ted_scraper.py	44 bandi TED esiti rimossi dal pool di matching
4	Salvataggio works_count, citations, h_index su OpenAlex	entity/openalex.py	+250 segnali metrici (università + ricercatori)
5	Salvataggio description, language, n_repos su GitHub	entity/github_scraper.py	Tech stack persistito per le organizzazioni IT
6	Pulizia: numeri (citations, n_progetti...) esclusi da extra_kw del matcher	matching/match_engine.py	Keyword score torna ad essere semantico
7	Nuovo componente peso_score (15%): max log-scaled tra h-index, citations, n_progetti, n_repos	matching/match_engine.py	Premio Nobel sale al #1 dove pertinente; ENEA/CNR/Sapienza spiccano sui bandi territoriali
8	Nuovo componente geo_score (10%): match regione bando vs sede entità	matching/match_engine.py + scraper/db.py + scripts/backfill_regioni.py	Bando 'ACCORDO LAZIO': top 10 tutto Lazio

7.3 Pesi finali

Componente	Peso iniziale	Peso finale
tipo	0.35	0.30
settori	0.30	0.20
concept	0.20	0.15
keyword	0.15	0.10
peso	—	0.15

Componente	Peso iniziale	Peso finale
geo	—	0.10
Totale	1.00	1.00

8. Limiti noti e prossimi sviluppi

8.1 Limiti correnti

- **ANAC bloccato:** il portale dati.anticorruzione.it usa WAF, niente CSV scaricato. Nessun bando ANAC, nessun contratto vinto. Workaround: download manuale dei CSV.
- **MUR limitato:** lo scraping HTML è fragile, siamo a 2 PRIN hardcoded come fallback. Servirebbe un'API ministeriale o estrazione da PDF allegati.
- **OpenCoesione: filtro per soggetto inattivo.** L'API ignora silenziosamente *beneficiario*, *soggetto*, *q*. Il dettaglio del soggetto è però ricco e viene sfruttato.
- **Bug pre-esistente:** ministeri e regioni nello scraper OC vengono classificati come *azienda* per default fallback (l'API listing non espone *natura_giuridica*). Fix possibile: leggere natura giuridica dal dettaglio.
- **Coverage geo limitata:** solo 33% dei bandi e 22% delle entità ha regione persistita. Migliorabile leggendo *place-of-performance* da TED e *territori*] da OC progetti.

8.2 Idee di sviluppo (effort/impact)

Idea	Effort	Impact
Saltare WAF ANAC con Playwright headless → ingestare CSV	Alto	Alto
Estrazione PDF allegati MUR per descrizione completa bandi	Medio	Medio
Aggiungere <i>place-of-performance</i> TED al matching geo	Basso	Alto
Persistere CORDIS projects.title/subjects come segnali su organizzazioni	Medio	Alto
Fix <i>natura_giuridica</i> nello scraper OC (legge dal dettaglio)	Basso	Medio
Notifiche automatiche su bandi nuovi che matchano una entità soglia	Medio	Alto
UI web (Streamlit/FastAPI) per esplorare il DB senza CLI	Medio	Alto